DOI：10.11985/2025.02.036

基于深度学习的局部放电分类识别研究综述*

詹诗语　高国强　曹炳磊　李佳丽　曹　晗　刘　凯　陈　奎　吴广宁
(西南交通大学电气工程学院　成都　611752)

摘要：局部放电(Partial discharge，PD)是表征电气设备绝缘劣化状态的关键诊断指标，可有效诊断电力设备不同类型与不同程度梯度的绝缘缺陷。针对电力设备绝缘诊断评估老大难的问题，目前主要采用的是局放信号模式识别和绝缘状态评估。传统的分类和识别方法需要专家从原始数据中手动提取适当的特征，再使用这些特征来诊断 PD 类型和严重程度。同时，相关人工智能算法也逐步被开发，将手动提取的有效特征用于机器学习(Machine learning，ML)算法的输入。深度学习(Deep learning，DL)作为一种典型的人工智能算法，比传统 ML 方法具有更好的准确性，提供了更有效的自动识别技术，被广泛应用于 PD 的自动特征提取和分类。对 DL 在局部放电特征分类、状态评估的研究现状进行了分析，并结合智能电网、智慧轨道交通等领域的发展需求，对其未来发展趋势进行了展望。

关键词：分类识别；深度学习；特征提取；局部放电
中图分类号：TM215；TM855

Review on Classification and Recognition of Partial Discharge Rest on Deep Learning

ZHAN Shiyu　GAO Guoqiang　CAO Binglei　LI Jiali　CAO Han　LIU Kai
CHEN Kui　WU Guangning
(School of Electric Engineering, Southwest Jiaotong University, Chengdu 611752)

Abstract: Partial discharge(PD) is a key diagnostic index to characterize the insulation deterioration state of electrical equipment, which can effectively diagnose insulation defects of different types and gradients of electrical equipment. Aiming at the long-standing problem of insulation diagnosis and evaluation of power equipment, pattern recognition of partial discharge signal and insulation state evaluation are mainly used at present. Traditional classification and recognition methods require experts to manually extract appropriate features from the original data, and then use these features to diagnose the type and severity of PD. At the same time, related artificial intelligence algorithms are gradually developed, and the effective features extracted manually are used as the input of machine learning(ML) algorithm. As a typical artificial intelligence algorithm, deep learning(DL) has better accuracy than traditional ML methods, and provides more effective automatic recognition technology, which is widely used in automatic feature extraction and classification of PD. The research status of DL in partial discharge feature classification and condition assessment is analyzed, and its future development trend is prospected in combination with the development needs of smart grid, smart rail transit and other fields.

Key words: Classification and identification；deep learning；feature extraction；partial discharge

1　引言

局部放电(Partial discharge，PD)是电力设备绝缘在较强的电场作用下局部范围内发生的放电[1-2]。这种放电造成导体间的绝缘局部短接而不形成导电通道为限。每一次局部放电对绝缘介质都会有一些影响，轻微的局部放电对电力设备绝缘的影响较小，绝缘强度下降较慢；强烈的局部放电则会使绝缘强度很快下降。这是高压电力设备绝缘损坏的一个重要因素，因此，PD 测量和分析被广泛用于变压器、电力

* 国家自然科学基金资助项目(52007158，52377161)。20240418 收到初稿，20240805 收到修改稿

电缆、气体绝缘开关设备(Gas insulated switchgear，GIS)等电气设备绝缘劣化的诊断指标[3-6]。

对局部放电信号特征提取、辨识，并建立其与电气设备绝缘状态的映射关系是局部放电技术的关键，人工智能算法对 PD 信号的研究逐渐成为关注焦点。近年来，人工神经网络的研究热潮愈来愈烈，深度学习(Deep learning，DL)的概念源于人工神经网络的研究，含多个隐藏层的多层感知器就是一种深度学习结构[7]。作为深层次的神经网络结构，其具有强大的非线性拟合能力和特征提取能力，能够处理巨量的高维度数据，高效地对数据进行识别和分类[8]。

本文对深度学习在 PD 分类识别应用进行了全面的综述。与同类文章相比，本文从不同深度学习网络出发，重点介绍了各种深度学习网络；综述了深度学习在 PD 分类识别的应用；通过总结该领域现有方法或技术的优缺点，指出了可能存在的问题，并提出了未来研究的建议和可能的解决方案。

2 局部放电检测方法与特征辨识

PD 作为判断电力设备状态的一项重要指标，已被国际电工委员会列入检测标准[9-10]。因此，要加强监测运行中的设备，当局部放电超过一定程度时，应将设备退出运行，进行检修或更换。对 PD 的检测可以指示设备的绝缘状态，对其进行正确识别可以帮助找到该缺陷的真正来源。当 PD 现象发生时，会产生极快的瞬态电流脉冲，可以在时域中表示为单个 PD 脉冲波形，如图 1 所示，其上升时间和脉冲宽度取决于放电类型或缺陷类型。目前常用的 PD 检测方法主要有脉冲电流法[11-13]、超高频法(Ultra high frequency，UHF)[14-17]、超声波法[18-19]和高频电流法(High frequency current transformer，HFCT)[20-22]。常用的 PD 检测方法及其各自优缺点如表 1 所示。

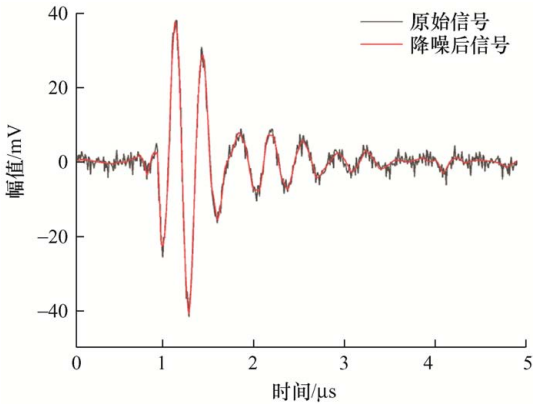

图 1 局部放电波形图

表 1 常用的 PD 检测方法及优缺点

检测方法	主要优点	主要缺点	主要应用范围
脉冲电流法	离线测量、灵敏度高	在线测量效果差	离线测试
超高频法	安装方便、灵敏度高	易受接地线环流影响	高压电缆电气设备
超声波法	抗电磁干扰能力强	灵敏度一般	电气一次设备
高频电流法	易操作、灵敏度高、抗干扰能力强	受地线环流影响	离线、在线测试

1995 年，SATISH 和 ZAENGL 首次将分形特征应用于 PD 识别[23]，以局部放电脉冲相位分布(φ-q-n)三维谱图的分维数和空缺率为特征量，研究了环氧树脂空隙放电的模式识别。随着数字化技术的发展，局部放电可以采用二维谱图、三维谱图、脉冲波形等表示，如图 2 所示为相位分辨局部放电(Phase resolved partial discharge，PRPD)谱图。从谱图中提取统计特征、分形特征、矩特征等用于模式识别。

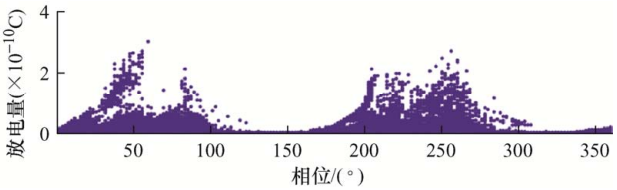

图 2 局部放电的 PRPD 图谱

PD 的表示与局部放电源的性质之间存在很强的相关性，从这些表示中提取区别特征，进而完成模式识别。文献[24]介绍了不同研究人员所使用的不同特征提取技术和 PD 分类方法。文献[25]调查了传统人工神经网络在 PD 分类中的应用。根据 PRPD 模式，可以计算统计偏度、峰度、平均值、方差和互相关等参数[26]。此外，还可以采用特征提取的方法对原始数据进行变换，如分形特征提取法[27]、小波分析法[28-29]、图像矩特征法[30-31]、统计特征法[32-33]、波形特征法[34]等，都可以用于从 PRPD 谱图中提取信息特征或者，通过傅里叶级数分析、Haar 和 Walsh 变换或小波变换等信号处理工具，可以从时域表示中获得特征[35-36]。然而，以上技术都只提供了半自动的特征提取，并且需要大量的专业知识。相关学者根据提取的参数特征向量使用反向传播(Back propagation，BP)神经网络[37-38]和支持向量机(Support vector machine，SVM)[39]在局部放电类型识别上取得了较好的分类效果。但是这些传统的局部放电类型识别方法都需要人为对信号进行特征提取，且特征的选取只是针对特定数据设置的，过于依赖领域专家对于某个问题而确立的方法，缺乏泛化性。

3　深度学习在 PD 分类识别的应用

深度学习是通过学习样本数据的内在规律，并从中获得有效信息对诸如声音、文字和图像等数据特征[40]。它的最终目的是让机器能够像人一样具有分析学习能力，能够识别文字、图像和声音等数据。深度学习是一个复杂的机器学习算法，特别是在语音和图像识别方面取得的成果，远远超过先前相关技术。

常见的深度学习方法有递归神经网络(Recurrent neural network，RNN)、对抗神经网络(Generative adversarial network，GAN)、自编码器(Auto-encoders，AE)和卷积神经网络(Convolutional neural network，CNN)等。

3.1　简易的深度学习结构

文献[41]提出了第一个应用于 PD 诊断的深度学习神经网络(Deep learning neural network，DNN)，对构造的六种不同的 PD 缺陷进行分类：① 不良电接触；② 浮动电位；③ 铜金属突起；④铝金属突起；⑤ 自由粒子和⑥ 表面放电，记录了 250～300 个 PRPD 谱图，用 UHF 传感器测量，但由于这个数量不足以训练 DNN，因此应用了数据增强，每个缺陷类型有 1 000 多个样本。

在文献[41]中，首先在传统神经网络结构的一个隐藏层中搜索神经元的最佳数量，发现从 75 个神经元开始具有良好的准确性，在 3 000 个神经元处达到总体峰值；然后，探索了包含 100 个神经元的隐藏层的 DNN 结构，从一层到七层，得出了五个隐藏层是最佳结构的结果；同时还比较了 ReLU 和 sigmoid 两种不同的激活功能，发现使用 ReLU 激活函数，识别准确率可以从 72%提高到 86%。虽然文献[41]只提出了一种简单的 DNN 结构，但对其他更复杂的 DNN 结构及其在 PD 分类识别的应用研究有很大启示作用。

3.2　RNN 在 PD 分类识别的应用

简单的 RNN 结构表示如图 3 左侧所示，其中一个隐藏层接收输入，产生输出，并将输出发送回自身。如果 RNN 表示在时间帧中展开，如图 3 右侧所示，则在每个时间步长 t，该递归层接收来自前一时间步长 $y(t-1)$的输入 $x(t)$及其自身的输出，用于分析和预测时间序列数据[42]。

RNN 中神经元分配了两组权重：w_x 用于输入 $x(t)$，w_y 用于前一时间步长的输出 $y(t-1)$。神经元过程的数学公式可以写成

$$y(t)=\varphi\left[\sum x(t)\cdot w_x+\sum y(t-1)\cdot w_y+b\right]$$

RNN 的主要特征是神经元对先前状态有短期记忆。当时间序列很长，且训练没有收敛到合适的解决方案时，来自梯度下降的更新使初始输入层的连接权重几乎不变，则出现梯度消失问题。该问题的解决方案是使用一个可以长期保持某些状态的神经网络层，也称为存储神经元。目前已经引入了各种类型的具有长期记忆的记忆神经元，其中最流行的是长短期记忆模型(Long short-term memory，LSTM)[43]。

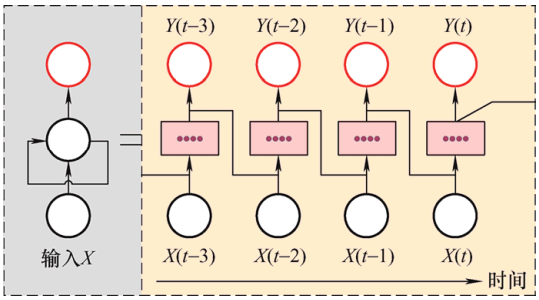

图 3　递归神经网络示意图

文献[44]提出了一个具有 LSTM 层的 RNN 结构，使用 Adam 优化算法来训练模型。最后，使用 softmax 层对四种不同的局部放电源(电晕、漂浮、自由颗粒和空隙缺陷)和一种噪声信号进行了分类。输入是 PRPD 信号的一个电力周期 M 内的 128 个数据点，所考虑的每个周期是该网络的时间步长，从而建立时间相关性。为了找到网络的最佳性能，对不同数量的功率循环 M 和 LSTM 层进行了评估，发现对于 M=60 个功率循环和两个 LSTM 层，该方法的准确率达到 96.62%，且准确率优于线性 SVM、带有径向基函数的非线性 SVM 和 BP 神经网络机器学习方法，但不足之处是训练耗时最长。文献[45]对从实验室测量的四种不同类型的局部放电信号进行训练，LSTM 模型的输入是单个 PD 信号波形。数据集由 42 794 个脉冲组成，且类别不平衡，结果发现使用类别不平衡脉冲数据集比将数据减少到平衡类别更能提高准确性。同时发现基于单个 PD 脉冲的分类是具有可行性和准确性的，可以替代 PRPD 数据；而在 PRPD 数据中，如果同时存在两个 PD 源，则模式会发生变化。虽然传感器获取的单个脉冲，可能由两个不同源产生的两个脉冲组合，但这两种 PD 现象发生在不同的时间，经过数据处理仍然可以在一个功率循环内检测到单独的脉冲。

文献[46]也采用 LSTM 模型，用于电力变压器四种运行状态(正常、注意、严重、危机)预测，考虑到随着时间跨度增大，变压器状态与较早之前的

状态相关性减弱，因此对变压器状态进行预测时应考虑时间轴上的相关性，并且 LSTM 网络在设计上明确地避免了长期依赖的问题。最终结果显示该方法优于 BPNN 和 SVM 机器学习方法。

3.3 GAN 在 PD 分类识别的应用

GAN 结构由两个不同的阶段组成，由两个神经网络表示：生成器网络和鉴别器网络，如图 4 所示。生成器模拟来自某种概率分布的数据，通常称为随机输入的潜在表示。鉴别器估计样本来自真实数据或生成器的概率。当鉴别器不再能够区分真实数据和伪造数据时，训练结束，并且生成器网络可以用于生成新的模拟数据[47]。该模型主要应用于数据扩充，有时收集足够数据来训练 DNN 并防止模型过拟合是比较困难的，且可能成本比较昂贵。

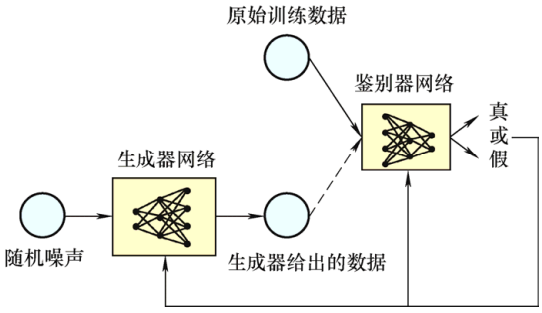

图 4 对抗神经网络示意图

在文献[48]中，通过使用 UHF 法测得了 PD 信号，并用一种 GAN 模型扩充了从 PD 模拟器试验的 PD 数据。为了对三个 PD 源进行分类，通过使用 GAN 提供的真实数据和虚拟数据对 DNN 进行训练，所提方案如图 5 所示。最后结果表明，当使用相同数量的真实和虚拟数据训练模型时，分类准确率最好，而当虚拟数据大于真实数据时，准确率开始下降。在文献[49]中，GAN 模型也被用于增强从变压器中制造的试验 PD 源的数据，解决现场采集到的局放样本数量较少且具有类间不均衡的特性的问题。

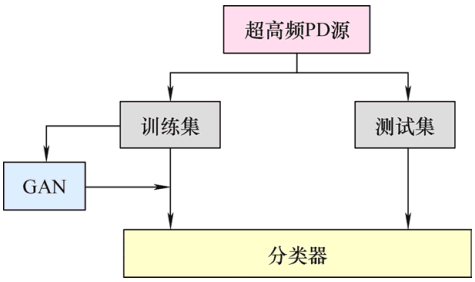

图 5 GAN 模型对 PD 源分类[48]

3.4 AE 在 PD 分类识别的应用

AE 模型被认为是无监督学习模型，能够生成输入数据的有效表示，即特征提取。如图 6 所示，编码部分将输入转换为内部表示，解码部分将该内部表示转换为输出，训练目标的输入向量与输出向量一致[50]。

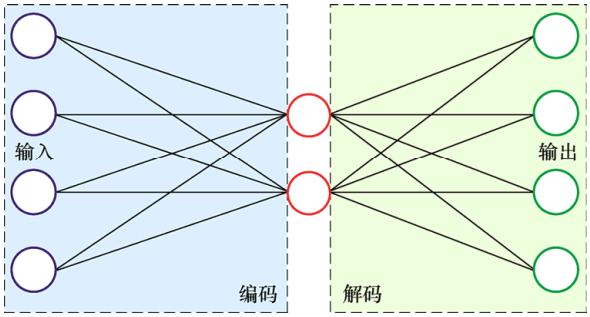

图 6 自编码器网络示意图

文献[51]提出了一种自编码器网络的 PD 信号的模式识别模型。通过使用脉冲电流法获得实验室中构造的 4 种不同放电类型的 PD 信号，每种放电类型训练样本 100 个、测试样本 50 个。随后，采用变分模态分解对 PD 信号进行分解，对所得各分量进行 Hilbert 变换构建相应的 Hilbert 边际谱，构建数据集。再将此数据集作为稀疏自编码器(Sparse autoencoder，SAE)的输入数据，通过 SAE 自动学习和训练 DNN，完成 PD 信号的模式识别。最后与 BP 神经网络和 SVM 机器学习方法识别结果对比，结果表明该识别方法的识别准确率更高。文献[52]提出了一种自编码器结构，更准确地说，是一种堆叠稀疏自编码器(Stacked sparse autoencoder，SSAE)，模拟了 GIS 外壳中四种不同缺陷程度，采用 UHF 法测得 PD 信号。使用 SSAE 提取模态分解后的局部放电信号特征，最后一层使用 softmax 分类器实现状态评估，并与 SVM 机器学习方法进行比较，最终结果 SSAE 整体识别准确率更高。

3.5 CNN 在 PD 分类识别的应用

CNN 模型是受到大脑视觉皮层的启发，但不局限于视觉感知，在信号处理和识别分类方面也很成功[53]。图像分类的主要任务是获得最能描述输入图像的类与类之间的不同特征。为了完成这项任务，该网络模型必须能够识别图像中边缘、曲线、脊等特征。基本的 CNN 结构如图 7 所示，其基本层如下：① 卷积层，在该层中，每个滤波器都应用于图像上沿图像连续位置的图像，并通过卷积运算生成特征图；② 非线性层，使用非线性激活函数，如 ReLU 函数，以避免系统中的线性；③ 池化层，该层的目的是通过减少特征图的大小来减少计算负载，并引入位置不变性；④ 全连接层，采用最后一个卷积层生成的卷积特征并进行预测的神经网络。输出误差由损失函数建立，以告知网络的准确性，

并最终使用优化器来提高其准确性[54]。

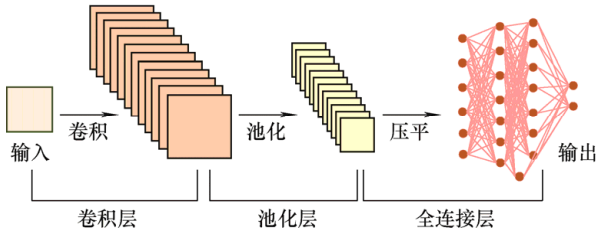

图 7　卷积神经网络示意图

3.5.1　卷积神经网络

文献[55]提出了卷积神经网络的方法应用于高压电缆局部放电信号分类，选择了 4 种缺陷类型用于试验，分别是绝缘表面划伤、绝缘表面金属污秽、绝缘内部气隙和、外半导电层爬电，利用 HFCT 测得 4 类缺陷生成的 PD 信号，采集原始数据并用于构建数据集。其次，考虑到数据类型为局部放电信号且各类信号间较为相似，选取了多层多核卷积结构，包含 2 个卷积层、2 个池化层、1 个展平层，2 个全连接层和 1 个输出层。对于 4 类 PD 信号，该方法的分类准确率均达到 98%以上，甚至对第三类和第四类 PD 信号的分类准确率能达到 100%。与 BP 神经网络机器学习方法和自编码神经网络方法相比，此方法分类准确率均较高，且其分类效果不受初始训练数据影响，并且训练时间较短。

文献[56]提出了一种基于卷积神经网络的 PD 模式识别深度学习方法。首先，在高压实验室对乙烯丙烯橡胶电缆中的五种人工缺陷进行局部放电测试，采用 HFCT 提取 PD 信号，每种缺陷类型 700 个样本。随后构建了 33 种 PD 特征，并将其作为模式识别方法、BPNN、SVM 和 CNN 的输入参数。并且讨论选择了 CNN 的结构：网络层数、卷积核大小、激活函数和池化方法。最终采用的 CNN 的最佳结构包括 3 个卷积层、3 个池化层和 1 个全连接层用于分类，如图 8 所示。最后，基于 CNN 的模式识别训练结果与 BP 神经网络和 SVM 机器学习方法相比，识别准确率分别提高了 6.47%和 4.76%。

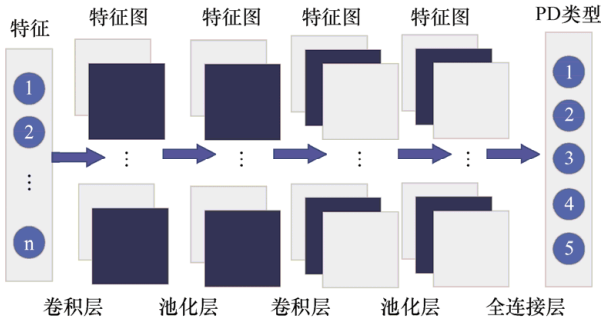

图 8　CNN 模型对 PD 源分类[56]

文献[57]提出了一种基于多尺度卷积神经网络的诊断方法。首先人工制作含四种典型缺陷(半导电层不均缺陷、环切划伤缺陷、金属铜箔缺陷和气隙缺陷)的动车组电缆试样，每种 300 个训练样本和 200 个测试样本。基于检测阻抗法，通过 MPD 600 和 CPL 542 局部放电信号进行采集和转换，并通过 MCU 502 将采集信号传输至 PC 进行分析，并构建数据库。文献[57]使用的多尺度卷积网络以 VGG-11 卷积神经网络为基础的深度网络结构，其核心思想是将卷积神经网络进行多尺度化学习。在 VGG-11 的基础上新增 2 条具有不同卷积大小的支路来表达提取特征的多尺度性，如图 9 所示。最终 10 次训练结果的准确率在 94%～97%。

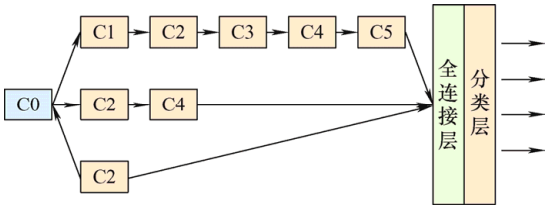

图 9　多尺度 CNN 对 PD 源分类[57]

3.5.2　改进型卷积神经网络

文献[58]提出了采用卷积神经网络框架 CAFFE 进行网络训练和识别检测。首先采集四种典型绝缘缺陷电缆的局部放电信号作为样本，采用 HFCT 法测试，获得了每种缺陷类型 70 个训练样本和 40 个测试样本。文献[58]提出了 CAFFE 框架包含三个核心模块：Blob、Layer 和 Net。其中 Blob 是用于存储数据的 N 维向量；Layer 是神经网络的核心，定义了例如卷积、池化、损失的层结构；Net 定义了一个以 Blob 为输入和输出，由多层 Layer 组合的有向无环图的完整网络，如图 10 所示。利用自适应的卷积核对样本进行特征提取，池化层进行特征映射，非线性多分类器进行回归分类，最终得到训练完成的 CAFFE 网络。通过设置不同求解器参数、网络结构和训练样本数量对缺陷识别结果进行对比分析，CAFFE 网络的模式识别的最高识别准确率达到了 91.32%，比 BP 神经网络和 SVM 机器学习方法识别准确率高。

文献[59]提出了一种新的基于 PRPD 谱图的 MobileNets 卷积神经网络(MCNN)模型来识别变压器的四个典型 PD 缺陷。试验采用 UHF 法，将 PD 数据转换成 PRPD 谱用于构建样本数据库。MCNN 模型中卷积模块由 1×1 点卷积将输入特征通道的数量扩展到大量中间层，3×3 深度卷积提取和优化特征和 1×1 点卷积将特征压缩到输出通道给定的大小

组成，如图 11 所示。卷积模块的输入通道数为 N，输出通道数为 M。对于一定大小 $W\times H$ 的输入特征，扩展因子为 t，卷积核大小为 3，s 表示步长，NL 表示非线性函数。再增加轻量级注意力机制挤压和激励模块和非线性函数 swish。通过调整训练周期和学习率参数，发现当训练周期的数量为 100，并且在第 30、第 60 和第 90 个周期中将学习率设置为降低 10 倍时，该模型的综合性能最优。当学习率设置为 0.15，迭代次数为 100 时，该模型分类效果最佳。结果表明，MCNN 的平均识别准确率率达到了 98.55%，优于 ALEX、VGG16、ResNet-18 等深度学习方法。

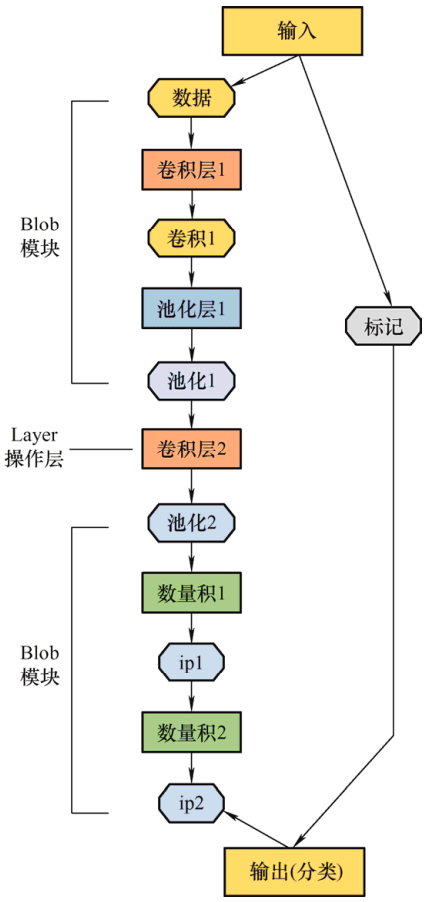

图 10 CAFFE 结构示意图[58]

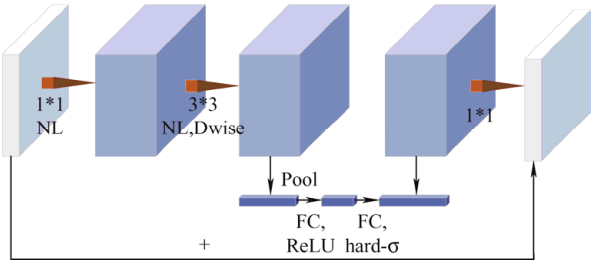

图 11 MobileNets 模块示意图[59]

3.6 联合神经网络在 PD 分类识别的应用

文献[60]提出了一种结合卷积神经网络在挖掘局部放电的局部空间信息的优势和长短期记忆网络在挖掘局部放电模式的时间信息的优点的 DNN 对变压器局部放电模式识别方法。文献[60]使用 UHF 法对电力变压器中四种典型绝缘缺陷测试，并通过图像预处理获得了 200 组训练样本，40 组测试样本。此方法的 CNN 网络设置为卷积层数为 5，池化层数为 5，LSTM 网络设置的层数为 1。将预处理的局部放电映射的单通道矩阵数据输入到网络中进行训练和识别，如图 12 所示。最后，该方法对电力变压器四种典型绝缘缺陷的识别结果分别是 90%、80%、89%、100%；与单独的 CNN 和单独的 LSTM 进行比较，该方法的准确率更高且训练用时更短。

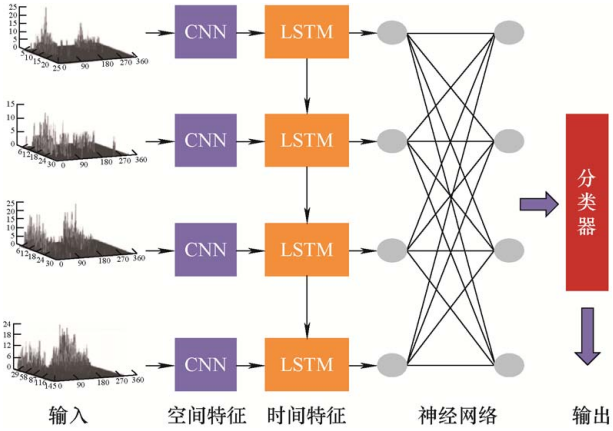

图 12 CNN 与 LSTM 结合的网络对 PD 源分类[60]

文献[61]也提出了一种联合 GAN 和 CNN 对 GIS 的 PD 信号分类的深度学习方法，试验采用 UHF 法测试，制造了 4 种类型的 PD 源来模拟各种绝缘缺陷，并通过 GAN 模型对试验收集的 PD 数据扩充，构建数据集，再将该数据集用于深度残差网络的输入，通过深度残差网络的模式识别最终完成分类，如图 13 所示。通过对比相同深度普通卷积神经网络和残差网络的识别准确率，该方法识别准确率提升约 13.5%。

综上所述，深度学习方法在解决 PD 信号识别分类问题中识别准确率超过了传统机器学习方法。表 2 为本节中解释的深度学习方法总结，深度学习对样本分类具有强大的自学习能力，本文从网络结构和算法实现的优缺点进行了总结如表 3 所示。随着学者们从简单的深度学习结构到单一的网络再到取长补短的联合网络，深度学习的方法在解决 PD 信号识别分类中表现出耗时短、特征提取强和准确率高等优势，如图 14 所示。

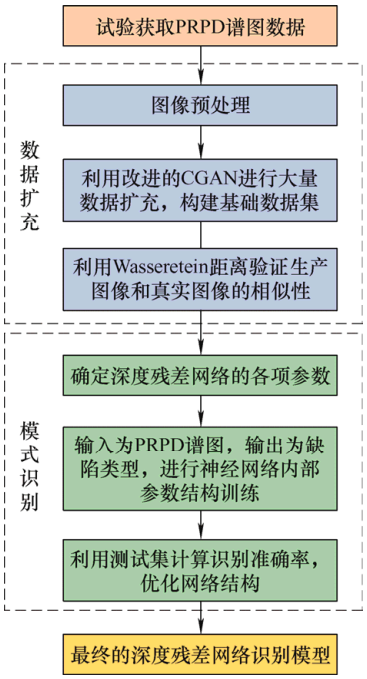

图 13　GAN 与 CNN 结合的网络对 PD 源分类流程图

表 2　深度学习方法总结

网络类型	类型/种	数据来源	检测方法
DNN[41]	6	实验室中人为构造	UHF
RNN LSTM[44]	4	实验室中人为构造	UHF
RNN LSTM[45]	4	实验室中人为构造	UHF
GAN[48]	3	局部放电模拟器	UHF
GAN[49]	4	实验室中人为构造	HFCT
AE[51]	4	实验室中人为构造	脉冲电流法
AE[52]	4	实验室中人为构造	UHF
CNN[55]	4	实验室中人为构造	HFCT
CNN[56]	5	实验室中人为构造	HFCT
CNN[57]	4	实验室中人为构造	脉冲电流法
CNN[58]	4	实验室中人为构造	HFCT
CNN[59]	4	实验室中人为构造	UHF
CNN+LSTM[60]	4	实验室中人为构造	UHF
GAN+CNN[61]	4	实验室中人为构造	UHF

表 3　深度学习方法的特点总结

网络类型	网络结构		算法实现	
	优点	缺点	优点	缺点
递归神经网络	具有循环连接结构，可以处理不定长的序列数据	计算复杂性较高，不适用于大规模数据和深度网络	处理序列数据和时序数据方面能力强	训练时间较长
对抗神经网络	主要由鉴别器和生成器构成，结构简单	训练稳定性一般	所需数据集小，生成高质量、多样化的数据	存在模式崩溃的问题
自编码器神经网络	主要由编码器与解码器构成，结构简单	在底层网络会出现梯度弥散现象	无监督学习，用于数据去噪和特征提取，且能学习数据的潜在特征	训练过程中可能存在过拟合
卷积神经网络	共享卷积核	结构比较复杂，且网络深度增加时，可能存在梯度爆炸	通过卷积层和池化层有效捕捉图像中的局部特征，对高维数据处理无压力	所需数据集大，且物理含义不明确

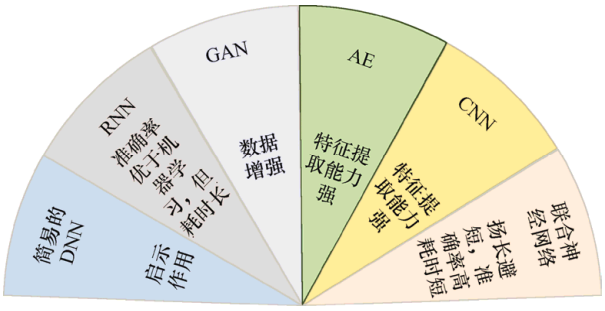

图 14　深度学习在 PD 分类识别的应用发展

4　总结与展望

本文对用于 PD 分类识别的深度学习方法领域最新进展进行了描述性总结。通过分析发现这些神经网络技术优于传统的机器学习技术，主要原因是 PD 原始数据可以提供给深度神经网络，自动学习每种类型局部放电最具代表性的特征，而无需手动特征提取。随着智能电网、智慧轨道交通的快速发展，现有 DNN 在 PD 信号的模式识别和状态评估领域尚存在不足之处，在以下方面还需要进一步发展。

(1) 数据集来源大多是用实验室模拟的人工局部放电的数据，且规律性还取决于随时间推移的 PD 发展、测量时的绝缘状态、施加的电压、记录时间和所使用的采集传感器。现场实测样本很少，不能证明已有的 DNN 模型适用于实际现场环境中，导致所训练的 DNN 模型缺乏泛化性。因此，建立一个基于多源信息的 PD 源的数据库是使该技术实用和高效的前提。

(2) 在所使用的 DNN 结构中，CNN 模型是最常用的，特别是在图像识别方面，CNN 是最优的训练模型。而 DNN 是通过随机训练算法学习的非线性方法，每个训练过程可能会找到一组不同的权重，从而产生不同的预测。更好的方法是使用集成学习，

即通过训练多个模型来减少 DNN 模型的方差。文献里也发现了两种模型的组合，如 CNN 与 GAN 或 LSTM 模型相结合，尽管它们被证明比传统的机器学习技术更准确，但最优 DNN 结构及其在智能电网中智能诊断的实用性仍有待发现。

(3) 在 PD 分类识别的深度学习方法领域最新进展中，用于 PD 的缺陷类型分类识别较多，缺陷程度的分类识别研究甚少，而在实际的电气环境中，缺陷程度的判断更能准确诊断运行中的设备，更方便对设备进行监测，并确定设备能否继续运行，及时对设备进行检修或更换。例如，就动车组车载电缆而言，随着运行时间的增长，缺陷程度也在逐渐加深。利用 DNN 在不同缺陷程度方面进行分类识别同样具有非常重大的意义，这意味着设备发生安全事故的概率降低，不仅起到了安全保障作用还更加经济。

(4) 目前在文献中没有发现 DNN 技术在实际电气环境中的应用。局部放电源的精准定位可以显著减少维护团队的响应时间和减小局部放电的影响范围。例如，就电缆中的局部放电而言，若能将局部放电源精确定位在几米以内，维护团队就能够直接前往现场并针对一小块区域进行检修；在变电站环境中，局部放电源可能更难判断，因此，局部放电类型识别应用于实际电气环境中是具有较高的工程价值。

在智能电网的背景下，在线监测技术更适用于 PD 识别，开发出实用且实惠的监测方案具有非常重要的意义。智能状态监测是诊断设备早期故障的关键解决方案，这需要智能算法从原始数据中提取有意义的信息进行预测，并提供准确、实时的设备健康方案。因此，深度学习方法可能是满足这些需求的绝佳选择。

参 考 文 献

[1] HAN Zhi. Depth selection for deep ReLU Nets in feature extraction and generalization[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence，2022，44(4)：1853-1868.

[2] LI Shuaibing，CAO Binglei，KANG Yongqiang，et al. Nonintrusive inspection of moisture damp in composited insulation structure based on terahertz technology[J]. IEEE Transactions on Instrumentation and Measurement，2021，70：1-10.

[3] MONTANARI G C. Partial discharge diagnostics：From apparatus monitoring to smart grid assessment[J]. IEEE Electrical Insulation Magazine，2013，29(3)：8-17.

[4] 李军浩，韩旭涛，刘泽辉，等. 电气设备局部放电检测技术述评[J]. 高电压技术，2015，41(8)：2583-2601.
LI Junhao，HAN Xutao，LIU Zehui，et al. Review on partial discharge measurement technology of electrical equipment[J]. High Voltage Engineering，2015，41(8)：2583-2601.

[5] 李清泉，王良凯，王培锦，等. 换流变压器油纸绝缘局部放电及电荷分布特性研究综述[J]. 高电压技术，2020，46(8)：209-223.
LI Qingquan，WANG Liangkai，WANG Peijin，et al. Review on partial discharge and charge distribution characteristics of oil-paper insulation in converter transformer[J]. High Voltage Engineering，2020，46(8)：209-223.

[6] STONE G C. Partial discharge diagnostics and electrical equipment insulation condition assessment[J]. IEEE Transactions on Dielectrics and Electrical Insulation，2005，12(5)：891-904.

[7] BARRIOS S，BULDAIN D，COMECH M P，et al. Partial discharge classification using deep learning methods-Survey of recent progress[J]. Energies，2019，12(13)：2485.

[8] 曹俊平，蒋愉宽，王少华，等. XLPE 电力电缆接头缺陷检测关键技术分析与展望[J]. 高压电器，2018，54(7)：87-97.
CAO Junping，JIANG Yukuan，WANG Shaohua，et al. Analysis and prospect of defect detection key technology for XLPE power cable joints[J]. High Voltage Apparatus，2018，54(7)： 87-97.

[9] 王昌长，李福祺，高胜友. 电力设备的在线监测与故障诊断[M]. 北京：清华大学出版社，2006.
WANG Changchang，LI Fuqi，GAO Shengyou. On-line monitoring and fault diagnosis of power equipment[M]. Beijing：Tsinghua University Press，2006.

[10] 周远翔，刘睿，张云霄，等. 高压/超高压电力电缆关键技术分析及展望[J]. 高电压技术，2014，40(9)：2593-2612.
ZHOU Yuanxiang，LIU Rui，ZHANG Yunxiao，et al. Key technical analysis and prospect of high voltage and extra-high voltage power cable[J]. High Voltage Engineering，2014，40(9)：2593-2612.

[11] International Electrotechnical Commission. IEC 60270：2000 Partial discharge measurements[S]. Geneva：IEC，2000.

[12] 国家市场监督管理总局，中国国家标准化管理委员会.

GB/T 7354—2018 高电压试验技术局部放电测量[S]. 北京：中国标准出版社，2018.
State Administration of Market Regulation of the People's Republic of China, Standardization Administration of the People's Republic of China. GB/T 7354 — 2018 High-voltage test techniques—Partial discharge measurements[S]. Beijing：Standards Press of China，2018.

[13] 陆云才，范路，陶风波，等. 人工智能在局部放电检测中的应用(一)：去噪与故障定位[J]. 绝缘材料，2021，54(5)：10-20.
LU Yuncai，FAN Lu，TAO Fengbo，et al. Application of artificial intelligence in partial discharge detection part Ⅰ：Denoising and fault location[J]. Insulating Materials，2021，54(5)：10-20.

[14] 郭灿新，张丽，钱勇，等. XLPE 电力电缆中局部放电检测及定位技术的研究现状[J]. 高压电器，2009，45(3)：56-60.
GUO Canxin，ZHANG Li，QIAN Yong，et al. Current status of partial discharge detection and location techniques in XLPE power cable[J]. High Voltage Apparatus，2009，45(3)：56-60.

[15] 许渊，刘卫东，陈维江，等. GIS 绝缘子局部放电高灵敏测量方法及应用[J]. 中国电机工程学报，2020，40(5)：1703-1711.
XU Yuan，LIU Weidong，CHEN Weijiang，et al. High-sensitivity measurement method and application of GIS spacer partial discharge[J]. Proceedings of the CSEE，2020，40(5)：1703-1711.

[16] 李国伟，章涛，王俊波，等. 基于超高频法的 GIS 局部放电类型判断方法[J]. 高压电器，2013，49(1)：63-68.
LI Guowei，ZHANG Tao，WANG Junbo，et al. Judgment of partial discharge types in GIS based on UHF method[J]. High Voltage Apparatus，2013，49(1)：63-68.

[17] 李化，杨新春，李剑，等. 基于小波分解尺度系数能量最大原则的 GIS 局部放电超高频信号自适应小波去噪[J]. 电工技术学报，2012，27(5)：84-91.
LI Hua，YANG Xinchun，LI Jian，et al. The maximum energy of wavelet decomposition approximation-related adaptive wavelet de-nosing for partial discharge UHF pulse in GIS[J]. Transactions of China Electrotechnical Society，2012，27(5)：84-91.

[18] 梁建英，孙传铭，杨刚，等. 基于声发射技术的典型缺陷局放信号特征分析及识别研究[J]. 电器与能效管理技术，2020(12)：14-21.
LIANG Jianying，SUN Chuanming，YANG Gang，et al. Study on characteristics and pattern recognition of typical defect emission signal based on acoustic emission technology[J]. Electrical & Energy Management Technology，2020(12)：14-21.

[19] 刘宇舜，程登峰，夏令志，等. 基于单通道盲源分离算法的局部放电特高频信号去噪方法[J]. 电工技术学报，2018，33(23)：5625-5636.
LIU Yushun，CHENG Dengfeng，XIA Lingzhi，et al. Partial discharge ultra-high frequency signal de-noising method based on single-channel blind source separation algorithm[J]. Transactions of China Electrotechnical Society，2018，33(23)：5625-5636.

[20] 李露露，高恩福，张明保，等. 利用电缆 HFCT 高速采样的系统暂态扰动辨识[J]. 高电压技术，2023，49(12)：4982-4992.
LI Lulu，GAO Enfu，ZHANG Mingbao，et al. System transient disturbance identification using cable HFCT high speed sampling[J]. High Voltage Engineering，2023，49(12)：4982-4992.

[21] 谢荣斌，杨超，申强，等. TEV 与 HFCT 法测量开关柜局部放电的特性对比[J]. 中国电力，2022，55(3)：37-47.
XIE Rongbin，YANG Chao，SHEN Qiang，et al. Comparison of characteristics between TEV and HFCT methods for measuring partial discharge of switchgear[J]. Electric Power，2022，55(3)：37-47.

[22] 周凯，黄永禄，何珉，等. 基于传输系数的 HFCT 电气参数测试方法研究[J]. 高压电器，2018，54(11)：301-306.
ZHOU Kai，HUANG Yonglu，HE Min，et al. Test method for electrical parameters of HFCT based on transmission coefficient[J]. High Voltage Apparatus，2018，54(11)：301-306.

[23] SATISH L，ZAENGL W S. Can fractal features be used for recognizing 3-d partial discharge patterns[J]. IEEE Transactions on Dielectrics and Electrical Insulation，1995，2(3)：352-359.

[24] RAYMOND W J K，ILLIAS H A，BAKAR A H A. Partial discharge classifications：Review of recent progress[J]. Measurement，2015，68：164-181.

[25] MAS'UD A A，ALBARRACÍN R，ARDILA-REY J A，et al. Artificial neural network application for partial discharge recognition：Survey and future directions[J]. Energies，2016，9(8)：574.

[26] GULSKI E，KREUGER H. Computer-aided recognition of discharge sources[J]. IEEE Transactions on Electrical Insulation，1992，27(1)：82-92.

[27] 李敏，汪沨，许松枝，等. 基于分形理论的 SF_6/N_2 混合气体放电仿真[J]. 电工技术学报，2016，31(24)：88-95.
LI Min，WANG Feng，XU Songzhi，et al. Simulation of discharge in SF_6/N_2 gas mixtures based on fractal theory[J]. Transactions of China Electrotechnical Society，2016，31(24)：88-95.

[28] 孙才新，李新，李俭，等. 小波与分形理论的互补性及其在局部放电模式识别中的应用研究[J]. 中国电机工程学报，2001，21(12)：73-76.
SUN Caixin，LI Xin，LI Jian，et al. Research on complementarity between wavelet and fractal theory and relevant application in PD pattern recognition[J]. Proceedings of the CSEE，2001，21(12)：73-76.

[29] 杜杰，程瑛颖，周峰，等. 油纸绝缘沿面放电小波矩特征信息提取及其过程划分[J]. 高压电器，2015，51(1)：61-66.
DU Jie，CHENG Yingying，ZHOU Feng，et al. Wavelet moment features extraction of surface discharge signals on oil-paper insulation and partition of the discharge process[J]. High Voltage Apparatus，2015，51(1)：61-66.

[30] CAO B，LI S，CUI Y，et al. Terahertz frequency domain response for insulation state assessment of vehicle cable terminal under electro-thermal aging[J]. CSEE Journal of Power and Energy Systems，2025，11(1)：458-467.

[31] 张晓虹，张亮，乐波，等. 基于局部放电的矩特征分析大电机主绝缘的老化[J]. 中国电机工程学报，2002，22(5)：94-98.
ZHANG Xiaohong，ZHANG Liang，YUE Bo，et al. Analysis on aging condition of stator winding insulation of generator based on the moment characteristics of partial discharge[J]. Proceedings of the CSEE，2002，22(5)：94-98.

[32] 胡文堂，高胜友，余绍峰，等. 统计参数在变压器局部放电模式识别中的应用[J]. 高电压技术，2009，35(2)：277-281.
HU Wentang，GAO Shengyou，YU Shaofeng，et al. Application of statistic parameters in recognition of partial discharge in transformers[J]. High Voltage Engineering，2009，35(2)：277-281.

[33] GULSKI E. Discharge pattern recognition in high voltage equipment[J]. IEE Proceeding on Science，Measurement and Technology，1995，42(1)：51-61.

[34] 黄兴泉，康书英，李泓志. GIS 局部放电超高频检测法有关问题的仿真研究[J]. 电网技术，2006，30(7)：37-40.
HUANG Xingquan，KANG Shuying，LI Hongzhi. Research on ultra-high-frequency method for detection of partial discharge in GIS[J]. Power System Technology，2006，30(7)：37-40.

[35] SAHOO N C，SALAMA M M A. Trends in partial discharge pattern classification：A survey[J]. IEEE Transactions on Dielectrics and Electrical Insulation，2005，12：248-264.

[36] LI Shuaibing，CAO Binglei，CUI Yi，et al. Terahertz-based insulation delamination defect inspection of vehicle cable terminals[J]. IEEE Transactions on Transportation Electrification，2023，9(1)：1765-1774.

[37] 张翼，朱永利. 结合知识蒸馏和图神经网络的局部放电增量识别方法[J]. 电工技术学报，2023，38(5)：1390-1400.
ZHANG Yi，ZHU Yongli. Incremental partial discharge recognition method combining knowledge distillation with graph neural network[J]. Transactions of China Electrotechnical Society，2023，38(5)：1390-1400.

[38] 姜国庆，李璐，李钊，等. 基于 BP 网络的高压电抗器局部放电模式识别[J]. 电气应用，2015，34(4)：86-89.
JIANG Guoqing，LI Lu，LI Zhao，et al. Partial discharge pattern recognition of high voltage reactor based on BP network[J]. Electrotechnical Application，2015，34(4)：86-89.

[39] 司良奇，钱勇，白万建，等. 基于支持向量机的 GIS 超高频局部放电模式识别[J]. 高压电器，2014，50(11)：1-6.
SI Liangqi，QIAN Yong，BAI Wanjian，et al. Pattern recognition of UHF partial discharge for GIS with support vector machine[J]. High Voltage Apparatus，2014，50(11)：1-6.

[40] 孙志军，薛磊，许阳明，等. 深度学习研究综述[J]. 计算机应用研究，2012，29(8)：2806-2810.
SUN Zhijun，XUE Lei，XU Yangming，et al. Overview of deep learning[J]. Application Research of Computers，2012，29(8)：2806-2810.

[41] CATTERSON V M，SHENG B. Deep neural networks for understanding and diagnosing partial discharge data[C]//Proceedings of the 2015 IEEE Electrical Insulation Conference (EIC)，June 7-10，2015，Seattle，WA，USA. New York：IEEE，2015：218-221.

[42] 张建海，周文晖，孔万增. 时滞递归神经网络鲁棒稳定性分析的统一方法[J]. 华中科技大学学报，2009，37(6)：28-31.
ZHANG Jianhai，ZHOU Wenhui，KONG Wanzeng. Unified approach for robust stability analysis of delayed recurrent neural networks[J]. Journal of Huazhong

University of Science and Technology，2009，37(6)：28-31.

[43] HOCHREITER S，SCHMIDHUBER J. Long short-term memory[J]. Neural Computer，1997，9：1735-1780.

[44] NGUYEN M T，NGUYEN V H，YUN S J，et al. Recurrent neural network for partial discharge diagnosis in gas-insulated switchgear[J]. Energies，2018，11：1202.

[45] ADAM B，TENBOHLEN S. Classification of multiple PD sources by signal features and LSTM networks[C]// Proceedings of the 2018 IEEE International Conference on High Voltage Engineering and Application(ICHVE)，September 10-13，National Technical University of Athens，Greece，2018：1-4.

[46] 代杰杰，宋辉，盛戈皞，等. 采用 LSTM 网络的电力变压器运行状态预测方法研究[J]. 高电压技术，2018，44(4)：1099-1106.
DAI Jiejie，SONG Hui，SHENG Gehao，et al. Prediction method for power transformer running state based on LSTM network[J]. High Voltage Engineering，2018，44(4)：1099-1106.

[47] 冯其红，李玉润，王森，等. 基于深度卷积生成对抗神经网络预测气窜方向[J]. 中国石油大学学报，2020，44(4)：20-27.
FENG Qihong，LI Yurun，WANG Sen，et al. Predicting gas migration development using deep convolutional generative adversarial network[J]. Journal of China University of Petroleum，2020，44(4)：20-27.

[48] WANG X，HUANG H，HU Y，et al. Partial discharge pattern recognition with data augmentation based on generative adversarial networks[C]//Proceedings of the 2018 Condition Monitoring and Diagnosis (CMD)，September 23-26，2018，Perth Western Australia，2018：1-4.

[49] 刘兆宸，谢庆，王春鑫，等. 基于 CycleGAN 与深度残差网络的局放数据增强与模式识别方法[J]. 高压电器，2022，58(11)：106-113.
LIU Zhaochen，XIE Qing，WANG Chunxin，et al. Partial discharge data enhancement and pattern identification method based on CycleGAN and deep residual network[J]. High Voltage Apparatus，2022，58(11)：106-113.

[50] 苗洛源，彭勇刚，胡丹尔，等. 基于自编码器-受限时序卷积网络的数据驱动配电网无功优化策略[J]. 高电压技术，2024，50(9)：4058-4068.
MIAO Luoyuan，PENG Yonggang，HU Daner，et al. Data-driven reactive power optimization strategy of distribution network based on autoencoder constrained temporal convolutional networks[J]. High Voltage Engineering，2024，50(9)：4058-4068.

[51] 高佳程，朱永利，郑艳艳，等. 基于 Hilbert 边际谱和 SAE-DNN 的局部放电模式识别方法[J]. 电力系统自动化，2019，43(1)：87-94.
GAO Jiacheng，ZHU Yongli，ZHENG Yanyan，et al. Pattern recognition of partial discharge based on Hilbert marginal speetrum andsparse autoencoder deep neural networks[J]. Automation of Electric Power Systems，2019，43(1)：87-94.

[52] TANG J. Assessment of PD severity in gas-insulated switchgear with an SSAE[J]. IET Science Measurement & Technology，2017，11(4)：423-430.

[53] 李世晓，杜锦华，龙云. 基于一维卷积神经网络的机电作动器故障诊断[J]. 电工技术学报，2022，37(S1)：62-73.
LI Shixiao，DU Jinhua，LONG Yun. Fault diagnosis of electromechanical actuators based on one-dimensional convolutional neural network[J]. Transactions of China Electrotechnical Society，2022，37(S1)：62-73.

[54] 曹美禾，宋琳，孙军，等. 深度学习及其在电机控制中的研究现状与展望[J]. 电机与控制应用，2023，50(5)：1-9.
CAO Meihe，SONG Lin，SUN Jun，et al. Research and prospect on deep learning and its application in motor control[J]. Electric Machines & Control Application，2023，50(5)：1-9.

[55] 吴剑，胡耀垓，姜春华，等. 基于卷积神经网络的高压电缆局部放电信号分类[J]. 武汉大学学报，2021，67(3)：232-240.
WU Jian，HU Yaogai，JIANG Chunhua，et al. Classification of partial discharge signals in high-voltage cables based on convolutional neural network[J]. Journal of Wuhan University，2021，67(3)：232-240.

[56] PENG Xiaosheng. A convolutional neural network-based deep learning methodology for recognition of partial discharge patterns from high-voltage cables[J]. IEEE Transactions on Power Delivery，2019，34(4)：1460-1469.

[57] 焦京海，曹伟东. 基于多尺度卷积神经网络的动车组电缆终端故障诊断研究[J]. 电工技术，2021(13)：29-32.
JIAO Jinghai，CAO Weidong. Research on fault diagnosis of EMT cable terminal based on multi seale convolution neural network[J]. Electric Engineering，2021(13)：29-32.

[58] 朱煜峰，许永鹏，陈孝信，等. 基于卷积神经网络的直流 XLPE 电缆局部放电模式识别技术[J]. 电工技术学报，2020，35(3)：659-668.

ZHU Yufeng，XU Yongpeng，CHEN Xiaoxin，et al. Pattern recognition of partial discharges in DC XLPE cables based on convolutional neural network[J]. Transactions of China Electrotechnical Society，2020，35(3)：659-668.

[59] SUN Y，MA S，SUN S，et al. Partial discharge pattern recognition of transformers based on MobileNets convolutional neural network[J]. Applied Sciences，2021，11(15)：6984.

[60] XI Y，YU L，CHEN B，et al. Research on pattern recognition method of transformer partial discharge based on artificial neural network[J]. Security and Communication Networks，2022(1)：5154649.

[61] 许辰航，陈继明，刘伟楠，等. 基于深度残差网络的 GIS 局部放电 PRPD 谱图模式识别[J]. 高电压技术，2022，48(3)：1113-1123.
XU Chenhang，CHEN Jiming，LIU Weinan，et al. Pattern recognition of partial discharge PRPD spectrum in GIS based on deep residual network[J]. High Voltage Engineering，2022，48(3)：1113-1123.

作者简介：詹诗语，男，1999 年生，硕士研究生。主要研究方向为高电压与绝缘技术。
E-mail：18990974125@163.com
高国强(通信作者)，男，1981 年生，博士，教授。主要研究方向为高电压与绝缘技术。
E-mail：xnjdggq@163.com